

ESCUELA POLITÉCNICA NACIONAL

FACULTAD DE INGENIERÍA EN SISTEMAS

CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

INFORME PRÁCTICA N°1

NOMBRE:

PAULA ROMO

DOCENTE:

CHRISTIAN SUÁREZ

FECHA: 19/10/2026

LINK REPOSITORIO:

https://github.com/paularomo2006/IDSD422-lab1-lectura-datos.git

1. Introducción

RetailAndina S.A. recibe cada semana información sobre sus ventas desde tres sistemas diferentes: el sistema de las sucursales (ERP), una plataforma de fidelización de clientes (API) y el área de Finanzas. Cada uno entrega los datos en un formato distinto; CSV, JSON y Excel. Por esta razón, fue necesario revisar los archivos para comprobar que contuvieran la misma información y que los datos estuvieran organizados correctamente. Durante esta práctica, utilicé Python y R para leer los archivos, identificar sus filas, columnas y tipos de datos, y realizar cálculos básicos sobre las ventas. Esto permitió obtener resultados que permitieron conocer el rendimiento de las sucursales y facilitar la toma de decisiones de la gerencia.

2. Objetivos

Objetivo General

- Analizar los reportes de ventas en CSV, JSON y Excel mediante Python y R para verificar la información y obtener indicadores de ventas.

Objetivos Específicos

- Leer los tres formatos de archivos utilizando Python y R.
- Comparar las filas, columnas y tipos de datos de cada archivo.
- Calcular los principales indicadores de ventas por sucursal y región.
- Interpretar los resultados para apoyar las decisiones de la empresa.

3. Desarrollo de la práctica

3.1. Preparación del repositorio y entorno de trabajo

Primero, realicé un fork del repositorio proporcionado por el docente en GitHub para tener mi propia copia del proyecto. Después, descargué el repositorio a mi computadora y lo abrí en Visual Studio Code. Además, utilicé **Google Colab** para ejecutar y comprobar los códigos de Python y **Posit Cloud** para trabajar con los códigos de R.

Revisé las carpetas del proyecto e identifiqué los archivos ventas.csv, ventas.json y ventas.xlsx, ubicados en la carpeta data. También encontré los scripts de Python y R que debía completar para leer, revisar y analizar la información.

3.2. Lectura de los archivos CSV, JSON y Excel

En este paso, utilicé Python y R para leer los tres archivos de ventas. Para cada formato fue necesario utilizar una función diferente.

Python:

```python
import pandas as pd

# Leer los tres archivos
csv = pd.read_csv("data/ventas.csv")
json = pd.read_json("data/ventas.json")
excel = pd.read_excel("data/ventas.xlsx")
```

R:

```r
library(jsonlite)
library(readxl)

# Leer los tres archivos
csv <- read.csv("data/ventas.csv")
json <- fromJSON("data/ventas.json")
excel <- read_excel("data/ventas.xlsx")
```

Después de ejecutar los scripts, comprobé que los archivos se cargaron correctamente y que podía visualizar sus datos.

3.3. Comparación e inspección de los datos

Después de cargar los archivos CSV, JSON y Excel, revisé que tuvieran la misma cantidad de filas y columnas. Para esto, utilicé shape en Python y dim() en R, que permiten conocer las dimensiones de cada archivo.

También revisé los tipos de datos de cada columna. En Python utilicé **dtypes** y en R la función **str()**, que me permitieron identificar qué tipo de información contenía cada variable.

Python:

```python
print(ventas.shape)
print(ventas.dtypes)
```

R:

```r
print(dim(ventas))
str(ventas)
```

Al ejecutar el código, comprobé que los tres archivos tenían **5 filas y 4 columnas**, correspondientes a sucursal, region, ventas y clientes.

También revisé los tipos de datos para comprobar que fueran correctos. Identifiqué que ventas y clientes contenían valores numéricos, mientras que sucursal y region almacenaban texto.

Esta revisión me permitió comprobar que los archivos tenían la misma estructura y que los datos estaban en un formato adecuado para realizar los cálculos de ventas.

3.4. Cálculo de los indicadores de ventas

En esta parte, utilicé el script de inspección para calcular los principales indicadores solicitados en la práctica. Primero, creé la columna `ticket`, dividiendo las ventas entre la cantidad de clientes de cada registro.

```
ventas["ticket"] = ventas["ventas"] / ventas["clientes"]
```

Después, calculé la venta promedio por sucursal utilizando `groupby()` y `mean()`.

```
# Venta promedio por sucursal
venta_promedio = ventas.groupby("sucursal")["ventas"].mean()
print(venta_promedio)
```

Para calcular el ticket promedio general, dividí las ventas totales entre la cantidad total de clientes.

```
# Ticket promedio general
ticket_promedio = ventas["ventas"].sum() / ventas["clientes"].sum()
print(ticket_promedio)
```

Luego, utilicé `idxmax()` e `idxmin()` para identificar las sucursales con la mayor y menor venta.

```
# Sucursal con mayor venta
print(ventas.loc[ventas["ventas"].idxmax(), "sucursal"])

# Sucursal con menor venta
print(ventas.loc[ventas["ventas"].idxmin(), "sucursal"])
```

Finalmente, agrupé las ventas por región para identificar cuál obtuvo el mayor total.

```
# Ventas por región
ventas_per_region = ventas.groupby("region")["ventas"].sum()

# Región con mayor venta
region_mayor = ventas_per_region.idxmax()
print(region_mayor)
```

Estos cálculos me permitieron identificar las sucursales con mejores resultados y conocer cuál fue la región que registró más ventas durante la semana.

3.5. Registro de los avances en GitHub

Finalmente, guardé los cambios de los scripts y utilicé la terminal de Visual Studio Code para registrar los avances realizados.

Primero, utilicé **git add** para seleccionar los archivos modificados. Después, creé los commits con mensajes que describían los cambios **git commit -m "Mensaje".**

Una vez guardados los cambios, los subí a mi repositorio de GitHub mediante el siguiente comando:

git push origin main

4. ¿Qué aprendí con esta práctica?

En esta práctica aprendí a leer y trabajar con archivos CSV, JSON y Excel utilizando Python y R. También comprendí que, aunque los archivos tengan formatos diferentes, pueden contener la misma información. Aprendí a revisar la cantidad de filas, columnas y tipos de datos para comprobar que los archivos estén organizados correctamente.

También aprendí a utilizar GitHub para guardar mis avances mediante commits y subir los cambios con **push**. Considero que esta práctica fue útil porque me permitió aplicar lo aprendido en clase a un caso de una empresa.

5. Preguntas

1. ¿Cuántas filas y columnas tiene la tabla en cada uno de los tres formatos? ¿Fue igual en los tres? ¿Por qué?

Los tres archivos, CSV, JSON y Excel, tienen 5 filas y 4 columnas. Los resultados fueron iguales porque contienen la misma información de ventas, aunque están guardados en formatos diferentes.

2. ¿Qué tipo de datos se infirió para ventas y clientes? ¿Qué indicaría que salieran como texto?

En Python, las columnas ventas y clientes se identificaron como int64, mientras que en R se identificaron como datos numéricos (integer o double). Si aparecieran como texto, podría significar que existen datos incorrectos, como letras, símbolos o espacios, que dificultarían realizar los cálculos.

3. En Python, ¿qué estructura devuelve json.load y por qué hay que "aplanarla"?

La función json.load() devuelve una lista de diccionarios en esta práctica, donde cada diccionario contiene la información de una sucursal. Es necesario aplanarla para organizar los datos en una tabla con filas y columnas, lo que facilita su análisis y permite realizar cálculos.

4. ¿Para qué sirve indicar sheet_name/sheet al leer Excel?

Sirve para seleccionar la hoja específica de Excel que queremos utilizar, ya que un archivo puede contener varias hojas. En esta práctica, se seleccionó la hoja llamada ventas para acceder directamente a la información necesaria.

5. ¿Qué diferencia ves entre leer en Python y leer en R (conceptos, no sintaxis)?

En ambos lenguajes pude leer los mismos archivos y obtener resultados similares. La principal diferencia está en cómo se organizan y presentan los datos. En Python utilicé tablas llamadas DataFrame de pandas, mientras que en R trabajé con data frames y tibbles. Además, observé que R muestra información detallada sobre los tipos de columnas al leer algunos archivos. Ambos lenguajes permiten analizar los datos, aunque utilizan herramientas diferentes.

6. Conclusiones y recomendación

- Se logró leer correctamente los archivos CSV, JSON y Excel utilizando Python y R. Esto permitió comprobar que ambos lenguajes pueden trabajar con diferentes formatos de información.
- Los tres archivos presentaron 5 filas y 4 columnas, con datos numéricos para ventas y clientes, y datos de texto para sucursal y región. Esto permitió comprobar que la información tenía una estructura adecuada para su análisis.
- Se identificó que Guayaquil Centro fue la sucursal con mayores ventas, mientras que Cuenca registró las menores. Además, la región Sierra obtuvo la mayor venta total y el ticket promedio general fue de 38,07.
- Los indicadores obtenidos permitieron comparar las ventas entre sucursales y regiones, proporcionando información útil para conocer el rendimiento comercial de la empresa durante la semana analizada.

Se recomienda revisar y actualizar semanalmente los indicadores de ventas para identificar qué sucursales tienen mejores resultados y cuáles necesitan mejorar, de manera que la empresa pueda tomar decisiones basadas en la información obtenida.

7. Bibliografía y uso de IA

- Suárez, C. (2026). IDSD422-lab1-lectura-datos [Repositorio de laboratorio]. GitHub. https://github.com/christian-suarez1979/IDSD422-lab1-lectura-datos
- pandas development team. (s. f.). pandas documentation. https://pandas.pydata.org/docs/
- Villarroel-Riquelme, F. (s. f.). Introducción a la estadística con R y RStudio. RPubs. https://rpubs.com/Francisco_VR/estadistica_R

Declaración de IA: Para realizar esta práctica, utilicé ChatGPT como herramienta de apoyo para comprender algunas funciones de Python y R, resolver dudas sobre el código y mejorar la redacción del informe. Los resultados fueron obtenidos mediante la ejecución de los scripts y la revisión de los datos, procurando comprender cada procedimiento realizado.

8. Evidencias de ejecución (Anexos)

```
import pandas as pd

ventas = pd.read_csv("data/ventas.csv")
print(ventas.head())
#imprimir las dimensiones
print("Dimensiones:", ventas.shape)
#imprimir loa tipos de columna
print("\nTipos por columna")
print(ventas.dtypes)
```

```
            sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4            Cuenca  Sierra    8540       210
Dimensiones: (5, 4)

Tipos por columna
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 1. Lectura del archivo CSV en Python mediante Google Colab, mostrando los cinco registros, las dimensiones y los tipos de datos.

```
import json
import pandas as pd

with open("data/ventas.json", encoding = "utf-8") as f:
  datos = json.load(f)

ventas = pd.json_normalize(datos)
print(ventas.head())
#imprimir las dimensiones
print("Dimensiones:", ventas.shape)
#imprimir loa tipos de columna
print("\nTipos por columna")
print(ventas.dtypes)
```

```
            sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4            Cuenca  Sierra    8540       210
Dimensiones: (5, 4)

Tipos por columna
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 2. Lectura del archivo JSON en Python y verificación de sus filas, columnas y tipos de datos.

```python
import pandas as pd
ventas = pd.read_excel("data/ventas.xlsx", sheet_name= "ventas")
print(ventas.head())
print(ventas.shape)
print(ventas.dtypes)
```

```
           sucursal  region  ventas  clientes
0       Quito Norte  Sierra   12450       320
1         Quito Sur  Sierra    9870       265
2  Guayaquil Centro   Costa   15200       410
3   Guayaquil Norte   Costa   13980       372
4            Cuenca  Sierra    8540       210
(5, 4)
sucursal    object
region      object
ventas       int64
clientes     int64
dtype: object
```

Figura 3. Lectura del archivo Excel en Python y comprobación de la estructura de los datos.

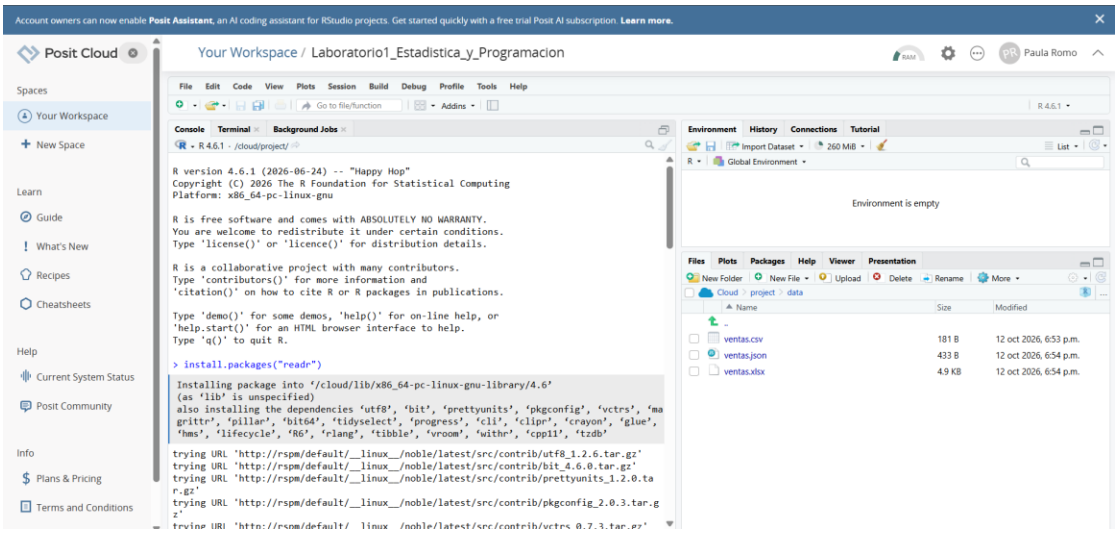


Figura 4. Instalación del paquete readr en Posit Cloud para facilitar la lectura de archivos CSV en R.

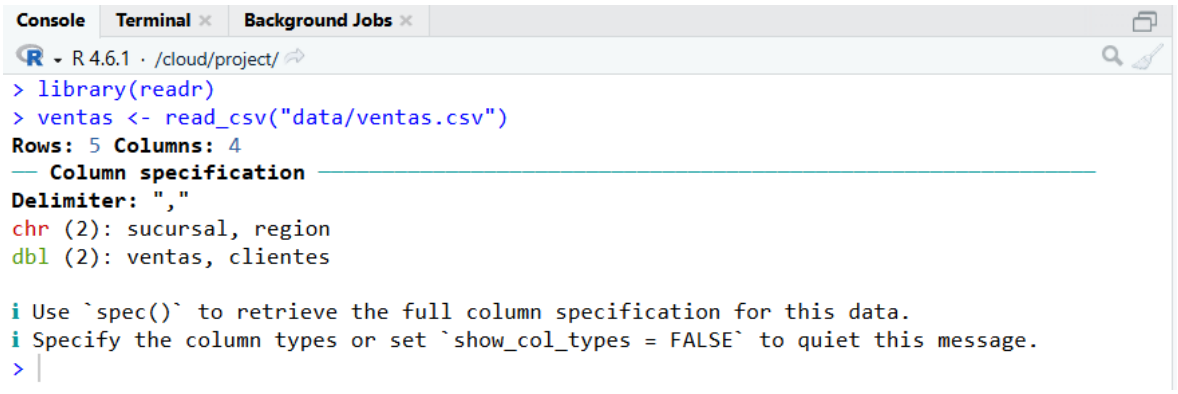


Figura 5. Lectura del archivo CSV en R mediante read_csv(), mostrando las dimensiones y los tipos de columnas identificados.

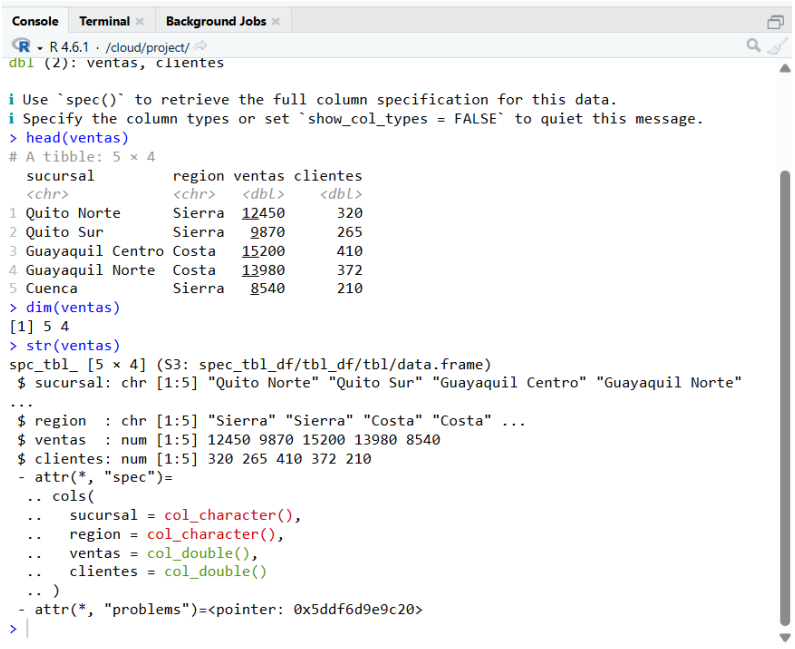


Figura 6. Visualización de los registros, dimensiones y tipos de datos del archivo CSV en R.

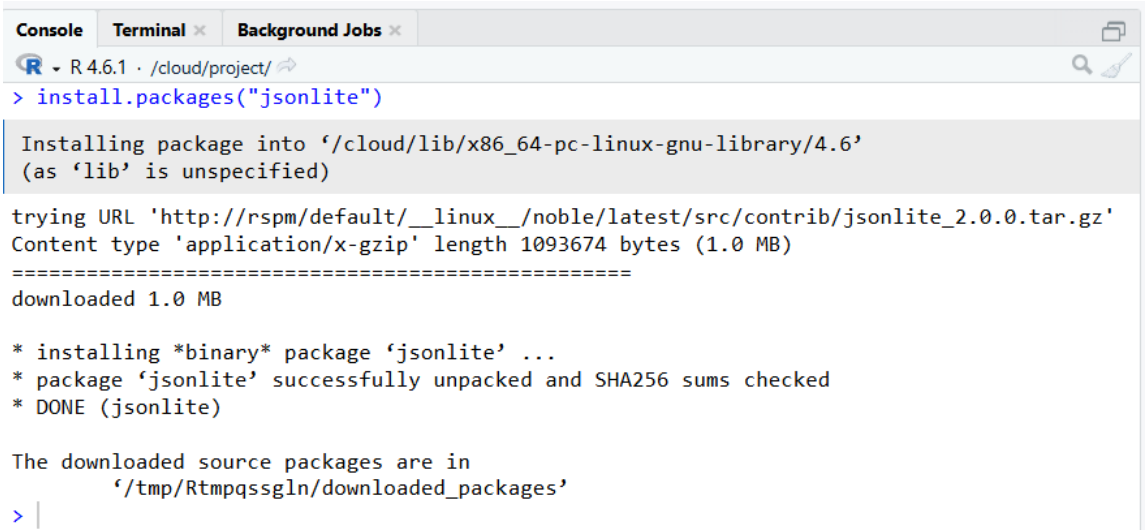


Figura 7. Instalación de la librería jsonlite en Posit Cloud para trabajar con archivos JSON.

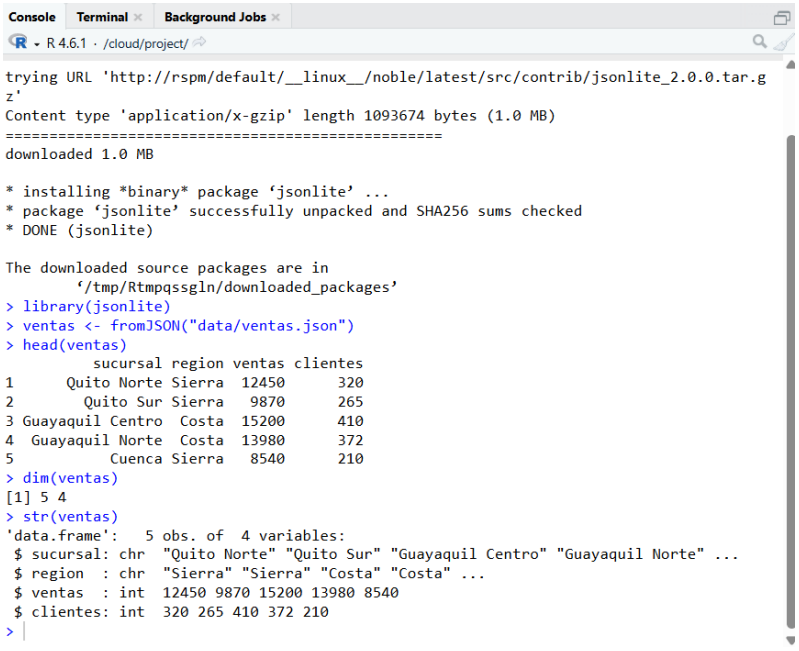


Figura 8. Lectura del archivo JSON en R y comprobación de sus cinco registros y cuatro variables.

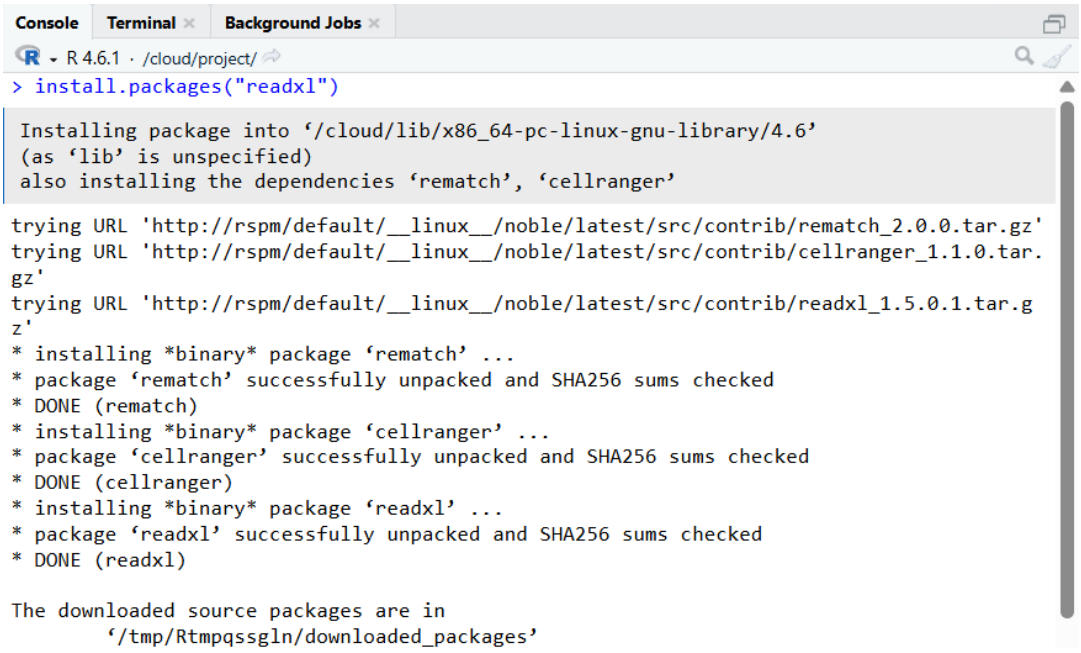


Figura 9. Instalación de la librería readxl en Posit Cloud para leer archivos Excel.

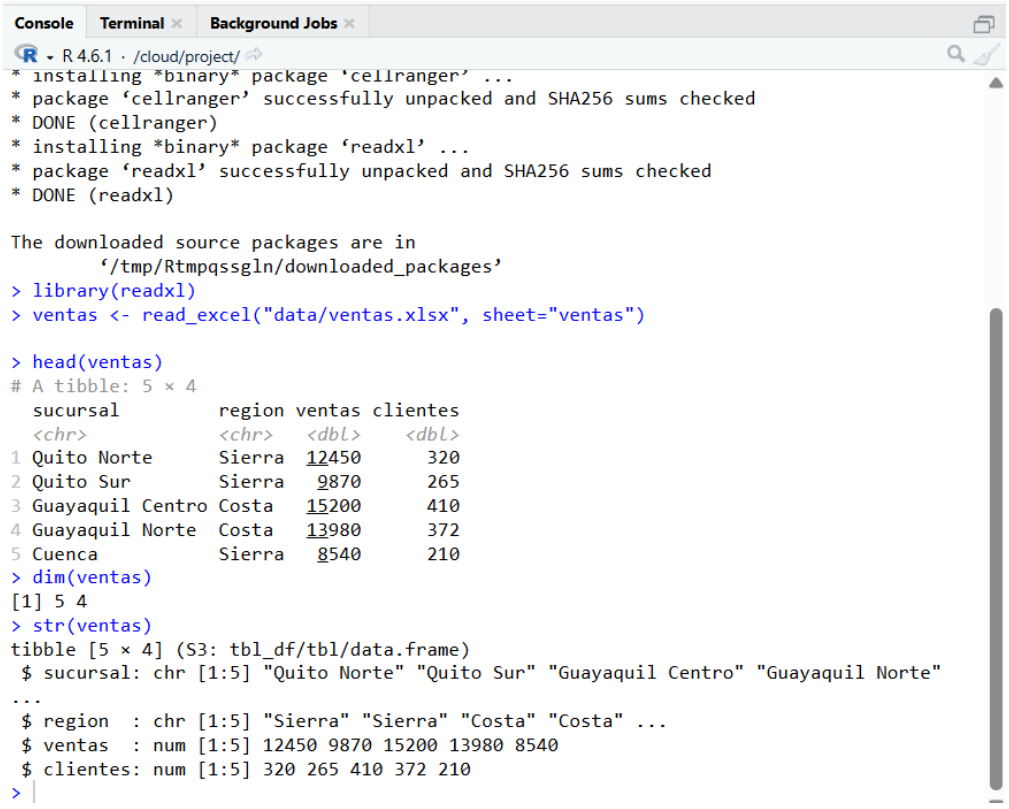


Figura 10. Lectura del archivo Excel en R y verificación de sus dimensiones y tipos de datos.

```r
# TODO 1: Cargar data/ventas.csv
ventas <- read.csv("data/ventas.csv")

# TODO 2: Imprimir los tipos de cada columna
str(ventas)

# TODO 3: Crear la columna derivada ticket = ventas / clientes
ventas$ticket <- ventas$ventas / ventas$clientes

print(head(ventas))

# TODO 4: Calcular e imprimir los indicadores

# Venta promedio por sucursal
print("Venta promedio por sucursal")
venta_promedio <- aggregate(ventas ~ sucursal, data = ventas, FUN = mean)
print(venta_promedio)

# Ticket promedio general (ventas totales / clientes totales)
print("Ticket promedio general")
ticket_promedio <- sum(ventas$ventas) / sum(ventas$clientes)
print(ticket_promedio)

# Sucursal con mayor venta total
ventas_sucursal <- aggregate(ventas ~ sucursal, data = ventas, FUN = sum)

sucursal_mayor <- ventas_sucursal$sucursal[
  which.max(ventas_sucursal$ventas)
]
```

Figura 11. Código en R para crear la columna ticket y calcular el promedio de ventas y el ticket promedio general.

```r
print("Sucursal con mayor venta:")
print(sucursal_mayor)

# Sucursal con menor venta total
sucursal_menor <- ventas_sucursal$sucursal[
  which.min(ventas_sucursal$ventas)
]

print("Sucursal con menor venta:")
print(sucursal_menor)

# Región con mayor venta total
ventas_region <- aggregate(ventas ~ region, data = ventas, FUN = sum)

region_mayor <- ventas_region$region[
  which.max(ventas_region$ventas)
]
```

Figura 12. Código en R para identificar las sucursales con mayores y menores ventas y la región con mayor venta total.

```
'data.frame':   5 obs. of  4 variables:
 $ sucursal: chr  "Quito Norte" "Quito Sur" "Guayaquil Centro" "Guayaquil Norte" ...
 $ region  : chr  "Sierra" "Sierra" "Costa" "Costa" ...
 $ ventas  : int  12450 9870 15200 13980 8540
 $ clientes: int  320 265 410 372 210
          sucursal region ventas clientes   ticket
1      Quito Norte Sierra  12450      320 38.90625
2        Quito Sur Sierra   9870      265 37.24528
3 Guayaquil Centro  Costa  15200      410 37.07317
4  Guayaquil Norte  Costa  13980      372 37.58065
5           Cuenca Sierra   8540      210 40.66667
[1] "Venta promedio por sucursal"
          sucursal ventas
1           Cuenca   8540
2 Guayaquil Centro  15200
3  Guayaquil Norte  13980
4      Quito Norte  12450
5        Quito Sur   9870
[1] "Ticket promedio general"
[1] 38.07229
[1] "Sucursal con mayor venta:"
[1] "Guayaquil Centro"
[1] "Sucursal con menor venta:"
[1] "Cuenca"
```

Figura 13. Resultados del análisis de ventas en R, mostrando el ticket promedio general y las sucursales con mayores y menores ventas.